

Pandas vs SQL

Diseño experimental de rendimiento en procesamiento de datos: Memoria RAM vs
Paginación en Disco Indexada.

Caso de Estudio: Contexto Caucasia

1

Generación de Datos Sintéticos (.csv)

Se estructuran tres fuentes de datos que simulan un volumen histórico y transaccional realista para saturar búsquedas secuenciales:

10,000

Clientes Maestros
(clientes.csv)

10,000

Datos Financieros
(ingresos_credito.csv)

1,000,000

Historial de Interacciones
(satisfaccion_operaciones.csv)

2

Consolidación e Inyección de Índices en SQL

Los archivos planos se unifican dentro de una base de datos SQLite (caucasia_negocios.db). Para garantizar una velocidad óptima, se aplican **estructuras de índices B-Tree** en las llaves de búsqueda:

```
CREATE INDEX idx_clientes_id ON clientes(identificador_cliente);  
CREATE INDEX idx_ingresos_id ON ingresos_credito(identificador_cliente);  
CREATE INDEX idx_satisfaccion_id ON satisfaccion_operaciones(identificador_cliente);
```

3

El Experimento en Clase (Objetivo)

Buscar un cliente específico (Ej: ID: 5555) realizando un cruce completo (JOIN / merge) para consolidar su sector económico, ingresos y todo su historial de satisfacción.

Enfoque A: Pandas

En Memoria RAM

- **La ilusión de la RAM:** Se ve obligado a parsear y estructurar el millón de filas del disco a la memoria antes de operar.
- **Búsqueda Secuencial:** Escanea fila por fila todo el DataFrame unificado para encontrar las coincidencias.
- **Riesgo latente:** Si los archivos pesaran gigabytes, arrojaría inmediatamente un error de falta de memoria (MemoryError).

Enfoque B: SQLite

Páginas de Disco Indexadas

- **El Vigilante Indexado:** Gracias al índice previo, el motor no lee las millones de filas; consulta un mapa ordenado (B-Tree).
- **Acceso Directo:** Salta exactamente al bloque físico del disco donde vive el cliente 5555.
- **Eficiencia Quirúrgica:** Extrae y monta en la RAM únicamente las filas deseadas, ignorando el resto del archivo.

Tiempo de Respuesta

0.8175 s

Tiempo de Respuesta

0.0046 s

RESULTADO DEL BENCHMARK

¡SQL fue 176.9x más rápido!

Conclusión pedagógica: Mientras Pandas intenta digerir un océano de información en la memoria RAM para responder por un solo individuo, SQL saca provecho de sus índices saltando directo al objetivo en milisegundos.